UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Centro de e-Learning
Secretaría de Cultura y Extensión Universitaria

Diplomado en Ciencia de Datos y Análisis Avanzado

Proyecto Final Integrador:

Predicción de intención de compra en sesiones de e-commerce

Grupo Nº6

Integrantes:

- Cicchitti, Silvana
- D'Amico, Pablo Ezequiel
- Maguina, Carla
- Morrone, Marianela
- Rey, Pablo Agustín

Fecha: 26/10/2026

1. Resumen ejecutivo

Este proyecto desarrolla un modelo predictivo para identificar en tiempo real la intención de compra de usuarios en un e-commerce. La solución permite a los equipos de Marketing y UX accionar tácticas de retención proactivas (descuentos dinámicos, asistencia en vivo), optimizando la Tasa de Conversión y el ROAS.

Metodología y resultados técnicos

- Riesgo mitigado: Se excluyó la variable PageValues por su alto riesgo de fuga de datos (data leakage).
- Modelo seleccionado: Regresión Logística, elegida por su interpretabilidad tras evaluar algoritmos de ensamble.
- Desempeño en Test (Umbral calibrado a 0,5055): Recall: 72,77% | Precision: 25,30% | F1-Score: 37,54%.

Nota: Se priorizó optimizar el Recall y el PR-AUC debido al severo desbalance de clases del negocio.

Impacto en el negocio

- Estrategia Top 20%: Interviniendo únicamente sobre el 20% de las sesiones con mayor probabilidad estimada, el modelo captura al 44,0% de los compradores reales.
- Eficiencia (Lift): Representa una efectividad 2,20 veces superior frente a una selección aleatoria de usuarios.
- Viabilidad: Permite maximizar el presupuesto comercial dirigiendo los incentivos exclusivamente al segmento con interés genuino, a validar mediante futuras pruebas A/B.

2. Definición del problema y relevancia

2.1 Contexto y motivación

- **Baja conversión del sector:** En el e-commerce, históricamente solo entre el 1.5% y el 4% de las sesiones masivas finalizan en compra.

- **Problema de negocio:** Existe una incapacidad para diferenciar en tiempo real a los usuarios que navegan por entretenimiento de aquellos con intención real de compra.
- **Impacto negativo:** Esta falta de diferenciación genera ineficiencias financieras y operativas (saturación de canales de soporte, emisión indiscriminada de promociones).

2.2 Objetivo concreto y medible

- **Meta principal:** Desarrollar un modelo predictivo supervisado que clasifique la probabilidad de conversión (`Revenue = True`) antes de que finalice la sesión.
- **KPI Técnico:** Maximizar la métrica de **Recall (objetivo ≥ 0.75)** sobre la clase compradora, manteniendo un PR-AUC y F1-Score competitivos ante el desbalance severo de clases.
- **Asimetría de costos:** Se prioriza la detección (Recall) sobre la Precisión porque un falso negativo cuesta la venta completa, mientras que un falso positivo solo consume una mínima fracción del margen comercial.

2.3 Importancia estratégica de negocio

Anticipar la intención de compra permite a la organización:

- **Optimización de presupuesto publicitario (ROAS):** focalizar campañas de *retargeting* dinámico únicamente en sesiones con alta probabilidad de abandono pero elevada intención de compra.
- **Personalización en tiempo real:** Disparar incentivos personalizados (descuentos temporales, asistencia por chatbot o avisos de stock limitado) de manera quirúrgica, protegiendo el margen de ganancia.
- **Eficiencia operativa:** Priorizar la infraestructura del servidor y el soporte al cliente en los embudos de pago (*checkout*) más críticos.

3. Datos y metodología

3.1 Marco Metodológico: Metodología CRISP-DM

El proyecto se desarrolló bajo este marco estándar iterativo a través de seis etapas:

- Comprensión del Negocio: Alineación estratégica y definición del KPI principal (Recall ≥ 0.75).

- Comprensión de los datos: EDA y evaluación del desbalance sobre 12.330 sesiones.
- Preparación de los datos: Partición 80/20 y diseño experimental (con/sin PageValues) para prevenir Data Leakage.
- Modelado: Entrenamiento de clasificadores (Regresión Logística, Random Forest, XGBoost) aplicando penalización de costos por el desbalance.
- Evaluación: Diagnóstico mediante múltiples métricas (PR-AUC, Recall, F1-Score) y análisis de interpretabilidad (Feature Importances).
- Despliegue e impacto: Traducción operativa y financiera de las predicciones (evaluación de estrategia sobre el Top 20%).

3.2 Fuente y descripción del dataset

Se trabajó con el dataset público *Online Shoppers Purchasing Intention* del repositorio UCI Machine Learning. El conjunto de datos recopila 12.330 sesiones de navegación web compuestas por 18 atributos (10 numéricos y 8 categóricos/temporales) y una variable objetivo binaria (Revenue).

La distribución de la variable objetivo refleja la realidad del sector:

- **Clase negativa (Revenue = False):** 10.422 sesiones (84.5%).
- **Clase positiva (Revenue = True):** 1.908 sesiones (15.5%).

3.3 Tratamiento metodológico de outliers

- **Identificación:** Se detectaron múltiples valores atípicos numéricos en las métricas de duración (ej. `ProductRelated_Duration`).
- **Conservación estratégica:** Siguiendo el feedback docente, no se eliminaron. En e-commerce representan sesiones reales de exploración intensa (*deep browsing*) y no errores de medición, conservando información clave de los usuarios más comprometidos.
- **Tratamiento técnico:** Para el modelo de regresión logística, las variables numéricas se estandarizaron con `StandardScaler`. La coherencia de los resultados obtenidos frente a modelos de árboles confirma la robustez de esta decisión.

3.4 Análisis crítico de Data Leakage (PageValues)

La variable PageValues mostró un fuerte poder predictivo durante el EDA (correlación de 0.49 con la conversión y un Odds Ratio de 32.18). Sin embargo, por su propia definición, esto sugiere un severo riesgo de fuga de datos (data leakage): si su valor se calcula incluyendo información post-transacción, el modelo fallaría en producción al no disponer del dato en tiempo real. Para mitigar este riesgo, la metodología evaluó todos los algoritmos sistemáticamente bajo dos escenarios:

- Escenario CON PageValues: Utilizando el conjunto completo de atributos (como diagnóstico).
- Escenario SIN PageValues: Excluyendo la variable para garantizar que el desempeño simule fielmente el entorno real de despliegue operativo.

4. Modelado y evaluación

4.1 Estrategia de validación y tratamiento del desbalance

Se implementó una partición estratificada 80/20 (9.864 sesiones de entrenamiento y 2.466 de prueba) para preservar el 15,5% de prevalencia de la clase positiva. Además, para gestionar el desbalance sin distorsionar la distribución original con técnicas de remuestreo sintético, se aplicó una ponderación de costos directamente en la función de pérdida de los algoritmos:

- class_weight='balanced' en Regresión Logística y Random Forest.
- scale_pos_weight = (N_neg / N_pos) en XGBoost.

4.2 Modelos evaluados

Se compararon tres familias de algoritmos:

1. **Regresión Logística (Baseline):** Con estandarización previa de variables numéricas mediante StandardScaler.
2. **Random Forest Classifier:** Ensamble del tipo *Bagging* con 200 estimadores.
3. **XGBoost Classifier:** Ensamble del tipo *Boosting* con optimización de gradiente.

Tabla comparativa de resultados

Evaluación de los modelos sobre el dataset de prueba (2.466 sesiones):

```
=== TABLA COMPARATIVA DE MODELOS Y MÉTRICAS ===
```

	Modelo	Precision	Recall	F1-Score	ROC-AUC	PR-AUC
0	Regresión Logística (CON PV)	0.5107	0.7487	0.6072	0.8962	0.6256
1	Regresión Logística (SIN PV)	0.2489	0.7356	0.3719	0.7318	0.3116
2	Random Forest (CON PV)	0.7433	0.5079	0.6034	0.9188	0.7197
3	Random Forest (SIN PV)	0.5455	0.0942	0.1607	0.7542	0.3386
4	XGBoost (CON PV)	0.6036	0.6937	0.6456	0.9163	0.6940
5	XGBoost (SIN PV)	0.2980	0.4188	0.3482	0.7325	0.3263

4.3 Análisis de desempeño y selección del modelo

- Efecto del Data Leakage: Al excluir PageValues, el PR-AUC general cae drásticamente (de ~0.69 a ~0.32). Por prudencia metodológica y ante la sospecha de que incluya información post-conversión, se descarta definitivamente para simular un entorno real.
- Selección del Modelo (Sin PV): La Regresión Logística superó ampliamente a los ensambles (Random Forest y XGBoost) en la detección de la clase positiva, logrando un Recall inicial de 0.735 frente a 0.418 y 0.094, respectivamente.
- Calibración del umbral: Mediante una validación independiente, se ajustó el umbral de decisión a 0,5055. El desempeño final en Test fue: Recall: 0.7277 | Precision: 0.2530 | F1-Score: 0.3754.

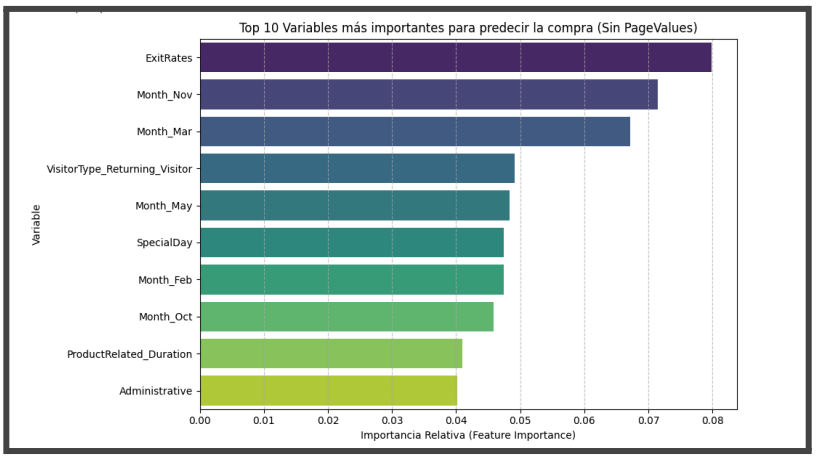
Conclusión: Aunque quedó ligeramente por debajo del 75% de Recall objetivo, la Regresión Logística se consolida como el modelo óptimo para producción por su alta interpretabilidad, facilidad de despliegue y desempeño comparativo superior. Se recomienda validar su impacto con pruebas A/B.

4.4 Análisis de variables predictoras (Feature Importances)

El análisis de interpretabilidad del modelo identifica tres impulsores clave en la decisión de compra:

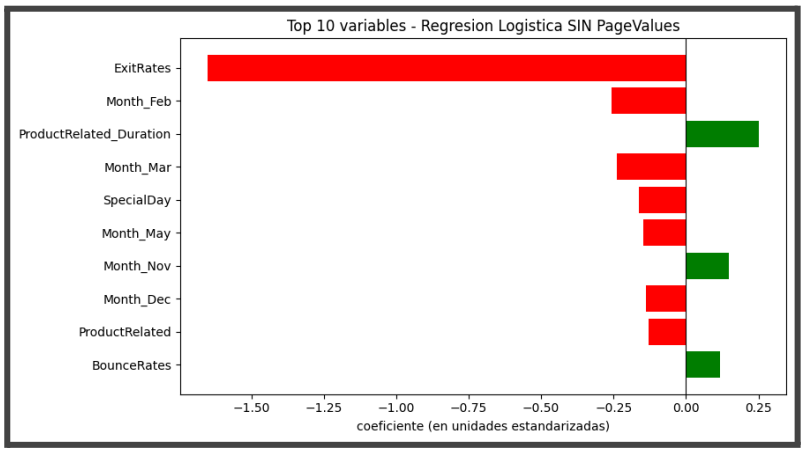
1. **Indicadores de abandono (ExitRates y BounceRates)**: Son los factores con mayor peso. Tienen correlación negativa con la conversión; la falta de profundidad en la navegación prácticamente anula la probabilidad de compra.

2. **Engagement de catálogo (ProductRelated_Duration)**: El tiempo de evaluación del producto es determinante. Su fuerte impacto positivo valida la decisión de conservar los outliers para capturar el comportamiento de deep browsing.
3. **Estacionalidad (Month_Nov)**: Refleja un pico transaccional basal en noviembre, alineado con eventos de alto tráfico (Black Friday / Cyber Monday).



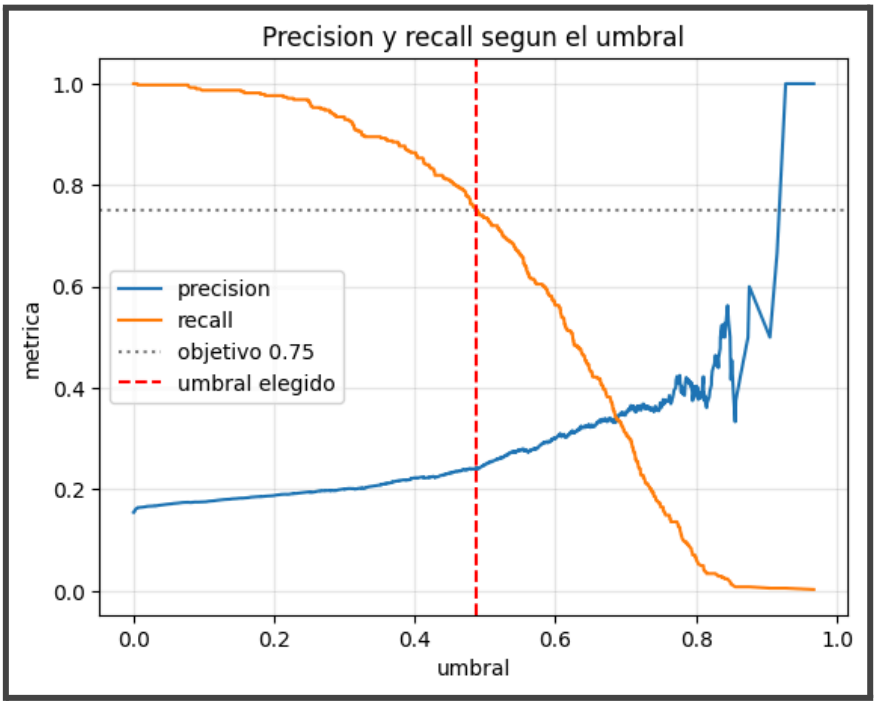
Coeficientes de la regresión logística

Las importancias de XGBoost muestran cuánto pesa cada variable; los coeficientes del modelo seleccionado agregan la dirección del efecto.



Los coeficientes precisan estos hallazgos: ExitRates es el predictor dominante y negativo, operando en bloque junto a BounceRates (debido a su altísima colinealidad) para captar la intención de abandono. En contrapartida, ProductRelated_Duration se consolida como el principal factor positivo, validando la decisión de conservar sus valores atípicos. Finalmente, la estacionalidad marca una fuerte influencia, ocupando seis de los diez lugares principales: noviembre destaca como el único mes con impacto positivo, frente a un febrero fuertemente negativo.

4.5 Ajuste del umbral de decisión



Para alinear las predicciones con la asimetría de costos del negocio, se reemplazó el umbral por defecto (0,500) por un valor calibrado de 0,5055, optimizado sobre un conjunto de validación independiente para evitar estimaciones optimistas. Si bien en validación este corte alcanzó el objetivo (Recall: 75,07%), su aplicación sobre el conjunto de prueba arrojó un Recall de 72,77% y una Precision de 25,30% (F1-Score: 37,54%), sin alterar la capacidad discriminativa intrínseca del modelo (ROC-AUC y PR-AUC). Adicionalmente, la dificultad para superar una Precision de 0,25 en la zona operativa confirma que, al excluir PageValues, las variables de navegación poseen una señal predictiva intrínsecamente limitada; una restricción estructural de los datos y no de los algoritmos evaluados.

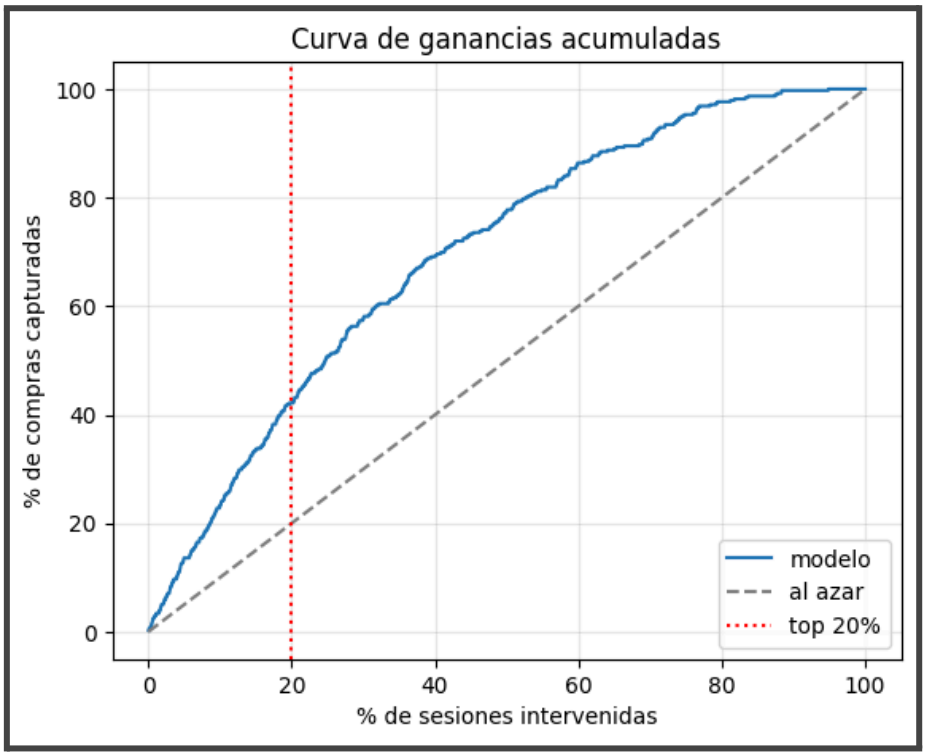
5. Impacto en el negocio

5.1 Beneficios esperados

Para traducir el desempeño del modelo a términos operativos, se evaluó intervenir únicamente sobre el segmento con mayor probabilidad de compra estimada:

- **Captura estratégica (Top 20%):** Al accionar sobre el 20% superior de las sesiones, el modelo captura al **44,0%** de los compradores reales.
- **Eficiencia comercial (Lift):** Esto genera un rendimiento **2,20 veces superior** a una asignación aleatoria, permitiendo alcanzar 92 compradores adicionales empleando el mismo presupuesto.

- **Asignación dinámica de recursos:** El análisis de distintos puntos de corte permite dimensionar la campaña según el costo unitario del incentivo:
    - *Incentivos de alto costo (ej. asistencia humana):* Aplicables al Top 5% o 10%, maximizando la eficiencia relativa (lift de hasta 2,72x).
    - *Incentivos económicos (ej. cupones automatizados):* Escalables al Top 20% o 30% para maximizar el volumen total de conversiones.



5.2 Riesgos y limitaciones

Precisión moderada. Con el umbral calibrado (0,5055), la Precision resultante es del 25,30%. Esto implica que 75 de cada 100 sesiones detectadas serán falsos positivos, lo que exige precaución al asignar incentivos de alto costo.

Predicción vs. causalidad. El modelo predice intención, no la respuesta al estímulo comercial (algunos usuarios habrían comprado de todos modos). Se requieren pruebas A/B o uplift modeling para medir el impacto incremental real.

Señal predictiva acotada. Al excluir PageValues por prudencia metodológica, el desempeño (PR-AUC ~0,33) revela un límite intrínseco en los datos de navegación. Si a futuro se garantizara su cálculo seguro en tiempo real, el rendimiento se duplicaría (PR-AUC 0,63).

Estabilidad y muestra. La fuerte estacionalidad detectada exige un monitoreo y reentrenamiento periódico. Asimismo, la evaluación se basó en una muestra acotada (382 compradores), dejando leves variaciones dentro del margen de error.

Generalización del umbral. Aunque se utilizó una partición de validación independiente para calibrar el umbral y evitar sesgos, el Recall final en Test (72,77%) no alcanzó el objetivo (75%). Se recomienda una evaluación final sobre datos completamente nuevos antes del despliegue productivo.

5.3 Escalabilidad y pasos futuros

El modelo de Regresión Logística es computacionalmente liviano, lo que permite su ejecución en tiempo real sin infraestructura compleja, mientras que su alta interpretabilidad facilita las auditorías de negocio o regulatorias. Para su implementación, se recomiendan los siguientes pasos:

- Trazabilidad de PageValues: Validar con el equipo de analítica web si es calculable en tiempo real, siendo esta la mejora de mayor impacto potencial.
- Medición de impacto: Diseñar pruebas A/B con grupo de control para cuantificar el efecto incremental real de las intervenciones comerciales.
- Recalibración financiera: Ajustar el umbral de decisión utilizando los costos reales (incentivo vs. ticket promedio) para maximizar el beneficio esperado en lugar del Recall.
- Enriquecimiento del modelo: Incorporar datos productivos adicionales (historial del usuario, dispositivo, contenido del carrito).
- Mantenimiento: Establecer rutinas de monitoreo del desempeño y reentrenamiento periódico.

5.4 Consideraciones éticas y de privacidad

Aunque el dataset académico utilizado presenta bajo riesgo por ser anónimo, su despliegue en producción exige cumplimiento normativo (Ley 25.326 y RGPD), requiriendo consentimiento expreso del usuario sin degradar la experiencia de quienes lo rechacen. Es fundamental auditar periódicamente el riesgo de discriminación indirecta, ya que variables como región o sistema operativo pueden actuar como proxies del nivel socioeconómico. Éticamente, el modelo debe restringirse a emitir incentivos positivos (descuentos o asistencia) y transparentes, evitando prácticas engañosas de falsa urgencia o la discriminación de precios al alza. Finalmente, la implementación debe garantizar la minimización de datos retenidos y mantener supervisión humana periódica sobre la asignación del presupuesto comercial.

6. Conclusiones y recomendaciones

6.1 Hallazgos principales

- Exclusión de PageValues: Aunque concentra la mayor señal predictiva, se descartó del modelo productivo por un riesgo fundado de fuga de datos (data leakage), ya que su cálculo podría incluir información post-transacción.
- Señal intrínseca limitante: Excluida dicha variable, los datos de navegación presentan un techo predictivo moderado (PR-AUC ~0.33), independiente del algoritmo evaluado. Reconocer esta limitación de los datos es un resultado central del análisis.
- Selección del modelo: Ante un desempeño similar entre familias de algoritmos, se seleccionó la Regresión Logística por su alta interpretabilidad y transparencia operativa para las áreas comerciales.
- Calibración y desempeño: Ajustar el umbral (0,5055) sobre un set de validación independiente fue crucial para evitar sesgos optimistas. El desempeño final en Test (Recall: 72,77%, Precision: 25,30%) quedó levemente por debajo del objetivo del 75%.
- Alto impacto de negocio: Pese a la limitación de los datos, la solución demuestra un gran valor operativo: intervenir sobre el Top 20% de las sesiones captura al 44,0% de los compradores reales, logrando una eficiencia 2,20 veces superior al azar.

6.2 Recomendaciones

- **Implementación piloto supervisada:** Desplegar el modelo únicamente como herramienta de priorización (ranking de sesiones) y no de decisión automática, validando su desempeño sobre datos nuevos antes de la adopción definitiva.
- **Prueba A/B controlada:** Diseñar un experimento con grupo de control para medir el efecto incremental real de las intervenciones antes de escalar el presupuesto.
- **Integración del calendario comercial:** Incorporar la estacionalidad en la planificación de campañas, considerando el fuerte impacto predictivo identificado en los meses clave.
- **Monitoreo, reentrenamiento y sesgos:** Establecer rutinas periódicas de actualización del modelo junto con auditorías éticas para prevenir sesgos indirectos.

6.3 Reflexión final

El principal aporte del proyecto no reside únicamente en las métricas alcanzadas, sino en la delimitación rigurosa de lo que los datos disponibles permiten y no permiten afirmar. La identificación del posible riesgo de fuga de datos asociado a PageValues y la posterior validación independiente del umbral de decisión permitieron reconocer limitaciones metodológicas que podrían haber conducido a conclusiones demasiado optimistas.

Si bien el modelo seleccionado no alcanzó completamente el objetivo de Recall establecido, demostró capacidad para identificar y priorizar sesiones con mayor probabilidad de conversión, concentrando al 44,0% de los compradores observados dentro del 20% de las sesiones mejor puntuadas. Este resultado representa una concentración 2,20 veces superior a la esperable mediante una selección aleatoria de igual tamaño, aunque no constituye evidencia de un incremento causal de las ventas.

En este sentido, el proyecto demuestra que el valor de la ciencia de datos no consiste solamente en desarrollar modelos con buenas métricas, sino también en evaluar críticamente sus resultados, reconocer sus limitaciones y traducir los hallazgos en recomendaciones comerciales fundamentadas y verificables.

7 Apéndice

Anexo A. Correspondencia entre el informe y el notebook

Las numeraciones de ambos documentos no coinciden: el informe sigue la estructura solicitada en la consigna y el notebook, el orden en que se desarrolló el análisis. La siguiente tabla indica dónde encontrar el desarrollo técnico que respalda cada apartado.

Sección del informe	Dónde está en el notebook
3.2 Fuente y descripción del dataset	2. Inspección inicial del dataset
3.3 Tratamiento de outliers	3. Análisis de outliers + 6.1
3.4 Análisis de Data Leakage	4. Análisis específico de PageValues
4.1 Validación y desbalance	5.2 División de los datos + 5.3 Desbalance
4.2 Modelos evaluados y tabla comparativa	5.1 Baseline + 5.6 Benchmark + 6.2 Métricas + 6.3 Entrenamiento
4.3 Desempeño y selección del modelo	6.5 Selección y justificación
4.4 Variables predictoras	6.4 Importancia de variables
4.5 Ajuste del umbral de decisión	6.6 Ajuste del umbral de decisión + 6.6.1 Validación independiente del umbral + 6.6.2 Comparación entre validación y test
5.1 Beneficios esperados (Top 20 %)	6.7 Impacto en el negocio
6. Conclusiones y recomendaciones	6.5 + 6.7

Anexo B. Enlaces al proyecto

- **Repositorio en GitHub (código y notebooks):** https://github.com/pablodamicopd/DCDDyAA_Grupo_6_Trabajo_Final

Dataset y fuente de Datos

- **Fuente**:https://archive.ics.uci.edu/dataset/468/online+shoppers+purchasing+intention+dataset

Material Académico y Metodología (Cátedra UTN.BA)

- **Material de Cátedra:** Universidad Tecnológica Nacional – Facultad Regional Buenos Aires (UTN.BA), Centro de e-Learning. *Diplomatura en Ciencia de Datos y Análisis Avanzado: Material didáctico, consignas y lineamientos metodológicos de las Unidades 1 a 9*.

Marco Regulatorio (consideraciones éticas)

- **Honorable Congreso de la Nación Argentina:** *Ley N° 25.326 de Protección de los Datos Personales* (B.O. 02/11/2000).
- **Unión Europea:** *Reglamento General de Protección de Datos (RGPD / Reglamento UE 2016/679)*.